

SAE Plans d'expériences

I. Définition

L'expérimentation permet de mieux comprendre un phénomène complexe en le remplaçant par un modèle plus simple, dans lequel on peut contrôler les éléments qui varient. L'objectif peut être de mieux connaître le système, de le maîtriser ou de l'améliorer.

Les éléments que l'on fait varier sont appelés facteurs. En les modifiant, on observe une réponse en sortie. Entre les deux, il y a tout un processus qui transforme les facteurs en résultats.

Pour organiser cette démarche, on utilise les plans d'expériences qui sont des outils clés pour prendre des décisions fondées sur des données et améliorer l'efficacité expérimentale. En effet, ce sont des méthodes statistiques utilisées pour organiser, réaliser et analyser des expériences de façon structurée. Leur objectif est de déterminer l'influence de plusieurs facteurs (variables d'entrée) sur une ou plusieurs réponses mesurées (variables de sortie), tout en minimisant le nombre d'essais nécessaires.

Grâce à ce plan, on peut identifier les facteurs significatifs et leurs interactions, optimiser un procédé ou un produit, quantifier l'incertitude et améliorer la fiabilité des conclusions.

II. Introduction :

Notre projet consiste à concevoir la meilleure recette de cookies sachant qu'un jury de dégustateurs doit goûter et noter nos différents cookies. Nous avons à notre disposition les quatre facteurs influents sur l'appréciation des cookies : la température du four (160°C ou 200°C), le type de pépites (formées industriellement ou des vrais morceaux de chocolat), le temps de cuisson (8 min ou 12 min), le type de chocolat (noir à 70% ou à 80%).

Dans le but de prévoir la note du jury, nous passons par les plans d'expérience.

III. Construction et interprétation du plan

A) Travail 0

Pour être sûr d'avoir l'appréciation maximale, nous réalisons le plan complet : tous les croisements possibles des niveaux des quatre facteurs soient $2 \times 2 \times 2 \times 2 = 2^4 = 16$ expériences. Pour simplifier la construction nous passons au codage des niveaux

Codage des niveaux :

Tempé (A): 160 -> -1 / 200 -> 1

Temps (B) : 8 -> -1 / 12 -> 1

Choco (C) : 0,7 -> -1 / 0,8 -> 1

Pépites (D) : Industriellement -> -1 / Vrai -> 1

B) Travail 1

Pour entrainer les dégustateurs, on décide de commencer par leur faire goûter un faible nombre de cookies. Pour cela, on ne s'intéresse qu'à deux facteurs (la température du four et le temps de cuisson) et des notes ont été attribuées à partir de ces deux facteurs. Dans ce cas le traitement se fera dans le cas de plan $2^2 = 4$ expériences (essais). Avec l'utilisation des codes de niveaux notre tableau devient.

Température	Temps	Note globale/100
160°C	8 min	34
160°C	12 min	54
200°C	8 min	68
200°C	12 min	42


A	B	Y
-1	-1	34
-1	1	54
1	-1	68
1	1	42

Nous constatons que :

A\B	-1	1
-1	34	54
1	68	42

- Quand A est fixé à -1 (Tempé = 160), le rendement augmente de 20
- Quand A est fixé à 1 (Tempé = 200), le rendement diminue de 26.

Ce qui signifie qu'il y'a **interaction entre les 2 facteurs (température et temps de cuisson)**. D'autre part le graphe suivant montre l'existence de cette interaction car les 2 courbes ne sont pas parallèles.



NB : Le rendement est plus élevé quand les deux facteurs sont de signes opposés (l'un au niveau bas et l'autre au niveau haut : interaction négative) que quand ils sont de même signe car $(\overline{AB -}) = 61$ et $(\overline{AB +}) = 38$. D'où $(\overline{AB -}) > (\overline{AB +})$.

Ainsi pour le calcul des effets de différents facteurs et de l'interaction, nous avons procédé au code R suivant :

```
install.packages("FrF2")
library(FrF2)
#Construction de la matrice des essais
plan = FrF2(nruns=4, nfactors=2)
plan
y=c(34, 54, 68, 42)
# Concaténation verticale (dans une table R : don) de la matrice des essais et y
don = cbind.data.frame(plan,y)
don

#Les effets de différents facteurs et interaction
#Calcul des moyennes de Y par niveau

#1-----Facteur A : température
moyA = tapply(don$y, don$A, mean)
moyA

plot(c(-1,1),moyA,type="l", col="blue", lwd=3, xlab="Température", ylab="Rdt")

abline(v =0, h =72.5, lty =4)

#2-----Facteur B : temps
moyB = tapply(don$y, don$B, mean)
moyB

plot(c(-1,1),moyA,type="l", col="red", lwd=3, xlab="Pression", ylab="Rdt")

abline(v =0, h =72.5, lty =4)


#Interaction
interaction.plot(don$B, don$A, don$y, type="b", xlab="B", ylab="Y", trace.label="A",
                 col=c("red","blue"))

#Evaluation d' Interaction
moy_AB_moins = (54+68)/2
moy_AB_plus = (34+42)/2

#Calcul des effets globaux par la méthode empirique
â = 1/4 *(-34-54+68+42)
beta = 1/4 *(-34+54-68+42)
gamma = 1/4 *(34-54-68+42)
û = 1/4 *(34+54+68+42)
```

Après cela, nous avons passé au traçage de la **surface des réponses** pour estimer le rendement à tous les points du domaine d'étude et estimer ainsi les paramètres du modèle.

```
#Surface de réponses du rendement en fonction de la température et du temps de cuisson
temperature = tempsCuisson = seq(-1,1,length=20)
model = function(x, y) {û + â*x + beta*y - gamma*x*y}
#calcule les valeurs estimées
rdt = outer(temperature, tempsCuisson, model)
persp(temperature, tempsCuisson, rdt, ticktype="detailed",
      theta=20, col="green")
```



Ce graphe nous montre une surface tordue, ce qui confirme l'existence d'une interaction entre nos 2 facteurs (température et temps).

Nous avons procédé au traçage de la courbe de niveau pour avoir un aperçu de la réponse Y estimée pour n'importe quel croisement des facteurs.

Pour trouver la fonction de cette courbe, nous avons procédé comme suit :

$$\text{Température} = (2x - (\max + \min)) / (\max - \min) \Rightarrow \text{Température} = (2x - (200 + 160)) / (200 - 160) \\ \Rightarrow \text{Température} = (x - 180) / 20$$

$$\text{Temps} = (2y - (\max + \min)) / (\max - \min) \Rightarrow \text{Temps} = (2y - (8 + 12)) / (8 - 12) \Rightarrow \text{Temps} = (y - 10) / 2$$

$$\text{D'où } f = 49,5 + 5,5 ((x - 180) / 20) - 1,5 ((y - 10) / 2) - 11,5 ((x - 180) / 20) ((y - 10) / 2)$$


$$f = 49,5 + 0,275x - 49,5 - 0,75y + 7,5 - 11,5 (xy - 10x - 180y + 1800) / 40$$

$$f = 49,5 + 0,275x - 42 - 0,75y - 0,2875xy + 2,875x + 51,75y - 517,5$$

$$f = -510 + 3,15x + 51y - 0,2875xy$$

Ceci a été réalisé avec le code R ci-après.

```
#Courbe de niveaux
model2 = function(x, y) {-510 + 3.15*x + 51*y - 0.2875*x*y }
temperature=seq(160,200,length=30)
tempsCuisson=seq(8,12,length=30)
rdt=outer(temperature,tempsCuisson,model2)
contour(temperature,tempsCuisson,rdt, xlab="Température", ylab="tempsCuisson", nlevel = 20,col="green", lwd=2)
```



Avec cette équation ou la courbe des prédictions sur la note peuvent être faites à partir des 2 facteurs.

Par exemple, pour :

a. Une température de **190 °C** et **10 min** de cuisson ?

On peut s'attendre à une note de : $-510 + 3.15 * (190) + 51 * (10) - 0.2875 * (190 * 10) = 52,25$

b. Une température de **185 °C** et **12 min** de cuisson ?

On peut s'attendre à une note de : $-510 + 3.15 * (185) + 51 * (12) - 0.2875 * (185 * 12) = 46,5$

4. Avec quelles combinaisons (température, temps), peut-on espérer une note d'environ 70 ?

- Pour une température de 202 et un temps de cuisson de 8 min, on peut avoir une note de 69,7
- Pour une température de 203 et un temps de cuisson de 8 min, on peut avoir une note de 70,55
- Pour une température de 204 et un temps de cuisson de 8 min, on peut avoir une note de 71,4

5. Avec quelles combinaisons (température, temps), peut-on espérer une note d'environ 80 ?

- Pour une température de 214 et un temps de cuisson de 8 min, on peut avoir une note de 79,9
- Pour une température de 215 et un temps de cuisson de 8 min, on peut avoir une note de 80,75
- Pour une température de 205 et un temps de cuisson de 7 min, on peut avoir une note de 80,18

C) Travail 2

Etant conscient que le nombre d'expériences croît très rapidement avec le nombre de facteurs. Des contraintes (temps, budget, ...) peuvent nous amener à réfléchir à réduire ce nombre. Plusieurs solutions peuvent être envisagées, comme omettre ou fixer certains facteurs ou choisir au hasard quelques expériences, ... mais cela peut altérer voire fausser le résultat final. La démarche des plans fractionnaires consiste à choisir judicieusement un sous ensemble d'expériences qui donneront le meilleur résultat. Certes, ces plans ne sont pas aussi précis que les plans complets (normal, on fait moins d'essais) mais, à moindre coût (budget, temps, ...), ils donnent des 28 résultats proches des plans complets. Pour mesurer cette précision, nous nous baserons, notamment, sur la variance des estimateurs.

Les membres du jury sont maintenant entraînés mais on décide, pour ne pas les gaver, de ne leur proposer que 8 cookies à évaluer donc on opte pour un plan factoriel $2^{(4-1)}$: on parle alors de plan fractionnaire $2^{(p-k)}$.

NB : Rappelons-nous que nous avons un quatrième facteur D, il va donc falloir le caser dans l'une des colonnes de la matrice des effets : le confondre avec l'une des colonnes (lui faire prendre la place d'une autre colonne). Ne pouvant le confondre avec 1 car cela reviendrait à le fixer au niveau (+1), ni avec A, B ou C car on ne saurait plus dissocier son effet de l'effet du facteur avec lequel il est confondu, nous allons le confondre avec l'interaction qui, en plus, à la propriété d'être orthogonale aux autres et on écrira $D = ABC$.

				D			
1	Température (A)	Pépites (B)	Chocolat (C)	AB	AC	DC	ABC
1	-1	-1	-1	1	1	1	-1
1	1	-1	-1	-1	-1	1	1
1	-1	1	-1	-1	1	-1	1
1	1	1	-1	1	-1	-1	-1
1	-1	-1	1	1	-1	-1	1
1	1	-1	1	-1	1	-1	-1
1	-1	1	1	-1	-1	1	-1
1	1	1	1	1	1	1	1

Dans le but de trouver les confusions ou alias, on passe par ces petites démonstrations :

Choisissons $D = ABC$
 $\Rightarrow DD = ABCD \Rightarrow ABCD = 1$ (générateur de confusion)
 $ABCD = 1 \Rightarrow AABCD = 1A \Rightarrow A = BCD$
 $ABCD = 1 \Rightarrow DABCD = 1D \Rightarrow B = ADC$
 $ABCD = 1 \Rightarrow CABCD = 1C \Rightarrow C = ABD$
 $A = BCD \Rightarrow AB = BCDB \Rightarrow AB = CD$
 $D = ABC \Rightarrow AD = AABC \Rightarrow AD = BC$
 $C = ABD \Rightarrow AC = CABD \Rightarrow AC = BD$

Ce qui nous permet de déduire le tableau de confusion.

	I	Température (A)	Pépites (B)	Chocolat (C)	AB	AC	AD	ABC
Confusion	ABCD	BCD	ADC	ABD	CD	BD	BC	D

Le déroulement de la démarche est synthétisé dans le tableau suivant où on a colorié effets confondus :

Plan factoriel 2^4	Plan fractionnaire $2^{(4-1)}$	
Les effets qu'on devrait avoir	Confusion	Reste(non colorés)
1	D = ABC	1
A	ABCD = 1	A
B	A = BCD	B
C	B = ADC	C
D	C = ABD	D
AB	AB = CD	AB
AC	AD = BC	AD
AD	AC = BD	AC
BC		
BD		
DC		
ABC		
ABD		
BCD		
ADC		
ABCD		

Pour rajouter les interactions et vérifier qu'on a bien une matrice d'Hadamard, nous avons exécuté ce code :

```

setwd("C:/Users/mdiout10/OneDrive - Université de Poitiers/2eAnnee/SAE_planExpérience")

install.packages("readxl")
library(readxl)
plan=read_excel("Classeur1.xlsx")

install.packages("FactoMineR")
library(FactoMineR)

# on récupère les colonnes correspondant à chaque facteur
a=plan[,1]
b=plan[,2]
c=plan[,3]
d=plan[,4]

ab=a*b
ac=a*c
ad=a*d

don=cbind.data.frame(plan,ab,ac,ad)
don
#Expulsion de la colonne Y
X=model.matrix(~. , data=don[ , -5])
X
#Diagonalisation
t(X)%*%X      #Là on peut dire qu'on a bien une matrice d'Hadamard

```

Dans ce code, nous avons d'abord lu notre fichier Excel qui comporte ce tableau :

Recette	A	B	C	D	Y
1	-1	-1	-1	-1	53
2	1	-1	-1	1	26
3	-1	1	-1	1	98
4	1	1	-1	-1	61
5	-1	-1	1	1	37
6	1	-1	1	-1	49
7	-1	1	1	-1	92
8	1	1	1	1	12

Puis nous avons créé les différentes interactions (ab, ac et ad). Ensuite nous avons éliminé la colonne des y pour mieux visualiser les facteurs ainsi que leurs interactions. Enfin, nous avons passé à la diagonalisation pour vérifier qu'on a bien une **matrice d'Hadamard**.


```

> #Expulsion de la colonne Y
> X=model.matrix(~. , data=don[ , -5])
> X
  (Intercept)  A  B  C  D A.1 A.2 A.3
1           1 -1 -1 -1 -1  1  1  1
2           1  1 -1 -1  1 -1 -1  1
3           1 -1  1 -1  1 -1  1 -1
4           1  1  1 -1 -1  1 -1 -1
5           1 -1 -1  1  1  1 -1 -1
6           1  1 -1  1 -1 -1  1 -1
7           1 -1  1  1 -1 -1 -1  1
8           1  1  1  1  1  1  1  1
attr(,"assign")
[1] 0 1 2 3 4 5 6 7
> #Diagonalisation
> t(X)%*%X      #Là on peut dire qu'on a bien une matrice d'Hadamard
  (Intercept)  A  B  C  D A.1 A.2 A.3
(Intercept)      8 0 0 0 0  0  0  0
A              0 8 0 0 0  0  0  0
B              0 0 8 0 0  0  0  0
C              0 0 0 8 0  0  0  0
D              0 0 0 0 8  0  0  0
A.1            0 0 0 0 0  8  0  0
A.2            0 0 0 0 0  0  8  0
A.3            0 0 0 0 0  0  0  8

```

NB : On parle de matrice **d'Hadamard**, toute matrice carrée dont tous les éléments sont égaux à 1 ou (-1) et dont les lignes sont orthogonales.

1) Pour avoir le modèle optimal, on passe à la sélection par étapes

La matrice des effets, X, est de dimension (8, 8), nous sommes, donc, en présence d'un modèle saturé (autant de paramètres à estimer que de lignes), il nous serait impossible de calculer SR (qui a aussi un ddl = 0).

Pour cela, on procède à l'**élimination des effets négligeables** : On repère le facteur ayant l'effet le plus faible en valeur absolue et on considère qu'il est négligeable. Il ne fera plus partie du modèle.

Le code R ci-après nous permet d'identifier cette interaction à négliger.

```

> #Estimation des effets
> theta = t(X) %*% don$Y/8
> theta
      [,1]
(Intercept) 53.50
A          -16.50
B           12.25
C           -6.00
D          -10.25
A.1        -12.75
A.2         -0.50
A.3         -7.75

```

Ici, nous allons considérer que l'interaction $AC = A.2 = -0,5$ est négligeable. A partir de maintenant, notre plan ne sera plus saturé (moins de paramètres à estimer que de lignes), nous pourrons alors utiliser les procédures statistiques des logiciels.

L'objectif étant de ne garder que les facteurs réellement influents sur Y (note du jury), on va procéder par éliminations successives jusqu'à l'obtention du **meilleur modèle**. Les paramètres de ce modèle seront obtenus grâce aux tests de significativité. Pour chaque paramètre (chaque ligne), on testera : **H0** : 'le paramètre est nul' contre **H1 = $\overline{H0}$** .

Si on accepte H0, le facteur correspondant sera considéré comme négligeable et exclu du modèle.

L'acceptation de H0 se fera au risque de **10%**. C'est à dire, toute les **p_valeurs** (colonne $\text{Pr}(> |t|)$) soient **inférieures à 0,1**.

```
> AovSum(Y~A+B+C+D +A:B+ A:D, data=don)
Ftest
```

	SS	df	MS	F value	Pr(>F)	
A	2178.0	1	2178.0	1089.00	0.01929	*
B	1200.5	1	1200.5	600.25	0.02597	*
C	288.0	1	288.0	144.00	0.05293	.
D	840.5	1	840.5	420.25	0.03103	*
A:B	1300.5	1	1300.5	650.25	0.02495	*
A:D	480.5	1	480.5	240.25	0.04102	*
Residuals	2.0	1	2.0			

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Ttest
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	53.50	0.50	107.0	0.00595	**
A	-16.50	0.50	-33.0	0.01929	*
B	12.25	0.50	24.5	0.02597	*
C	-6.00	0.50	-12.0	0.05293	.
D	-10.25	0.50	-20.5	0.03103	*
A : B	-12.75	0.50	-25.5	0.02495	*
A : D	-7.75	0.50	-15.5	0.04102	*

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> |
```

Avec ce tableau de test, nous constatons que toutes nos **$\text{Pr}(> |t|) < 0,1$**

Tous les effets sont significativement non nuls à 10% et même à 6 %, on garde donc ce modèle : $\hat{Y} = 53.50 - 16.50 * A + 12.25 * B - 6 * C - 10.25 * D + (-12.75) * AB - 7.75 * AD$ qui est notre **modèle optimal**.

On retrouve l'**écart-type** dans le tableau de test précédent dans la colonne Std. Error qui est égal à **0,5** et donc la **variance** est de **0,25**.

IV. Conclusion

Dans ce projet, nous avons comme mission de préparer la meilleure recette de cookies en fonction de 4 facteurs (la température du four, le type de pépites, le temps de cuisson et le type de chocolat) en vue d'obtenir la meilleure note de la part du jury. Afin de mieux réussir la recette, nous avons d'abord commencé à faire le test sur seulement deux facteurs (la température du four et le temps de cuisson) et recueillir les notes obtenues en fonctions de ces facteurs. A l'issu de ce test, nous avons établi la fonction qui nous permettrait de prévoir la note à partir de ces 2 facteurs. Ensuite, nous avons passé à l'intégration de l'ensemble des facteurs afin d'établir une fonction pour la prévision finale avec une sélection par étapes.

Bonus : Grâce à l'équation trouvée, on a su déduire le meilleur état des facteurs afin d'approcher la meilleure note/100 :

Par exemple, pour avoir une note de 86,5 : il faut une température de 180°, des pépites en morceaux, un chocolat à 80% et un temps de cuisson de 8min.