

Rapport d'Étude Statistique : Prédiction du Diamètre Tumoral

Sommaire :

1. Introduction et stratégie de modélisation
2. Nettoyage et robustesse des données
3. Analyse des valeurs atypiques
4. Comparaison des démarches et sélection du modèle
5. Interprétation de la variance (ST, SM, SR)
6. Influence des tests médicaux (Coefficients Beta)
7. Synthèse finale


1. Introduction et stratégie de modélisation

Dans le cadre de cette SAE, j'ai entrepris la construction d'un modèle de prédiction basé sur la **Régression Linéaire Multiple (RLM)**. L'objectif est d'estimer le diamètre d'une tumeur (Y) en utilisant dix indicateurs médicaux (X1 à X10). Ma démarche s'inscrit dans un pipeline complet de Machine Learning : j'ai structuré mon analyse pour passer d'une base de données brute, parsemée d'anomalies, à un modèle prédictif dont j'ai vérifié la stabilité par validation croisée. Cette rigueur est essentielle pour garantir que le modèle ne se contente pas d'apprendre par cœur les données d'entraînement (sur-apprentissage), mais qu'il capture les relations biologiques réelles entre les tests et la tumeur.

2. Nettoyage et robustesse des données

Le jeu de données initial présentait des valeurs manquantes (notamment sur X1, X3, et X7). Contrairement à une approche simpliste par la moyenne ou stratégie de départ basée sur la médiane où j'envisageais l'imputation, j'ai ici choisi de **supprimer** ces observations. Etant donné que sur 20 000 données, seules 3 ou 4 valeurs manquaient par variable (soit environ 0,02%). Cette proportion est négligeable ; en les supprimant, j'élimine tout risque d'erreurs de modélisation liés à l'imputation ou d'introduction de biais artificiel, garantissant que les prédictions reposent sur des mesures cliniques réelles et non "devinées".

[8 rows x 12 columns]	
identifiant	0
X1	3
X2	0
X3	4
X4	0
X5	0
X6	0
X7	4
X8	0
X9	0
X10	0
y	0




3. Analyse des valeurs atypiques

Une étape déterminante de mon travail a été la détection des points aberrants. J'ai mis en place un filtrage par le **Z-score** en fixant un seuil critique de 3 sigmas (trois écarts-types).

Ce choix repose sur les propriétés fondamentales de la **Loi Normale** : selon cette loi, 99,7% des observations d'une population doivent théoriquement se trouver dans cet intervalle. Bien que l'on ne puisse jamais garantir une normalité parfaite pour chaque variable médicale, j'ai pu m'appuyer sur la **puissance statistique liée à la taille de mon échantillon** (20 000 observations).

En vertu du **Théorème Central Limite**, la distribution des moyennes d'un échantillon de cette taille tend naturellement vers une loi normale. Dès lors, toute observation affichant un Z-score supérieur à 3 possède une probabilité mathématique d'existence extrêmement faible (inférieure à 0,3%). En supprimant ces 31 individus atypiques dans mon étude A, j'ai éliminé des points qui auraient exercé un "effet de levier" néfaste : ces points, par leur éloignement, attirent la droite de régression vers eux et dégradent la précision du modèle pour l'immense majorité des autres patients.



4. Comparaison des démarches et sélection du modèle

Pour valider mes choix, j'ai confronté trois scénarios de modélisation : le modèle "Brut" (C), conservant toutes les anomalies, a servi de base de comparaison. Le modèle avec suppression par Z-score (A) a atteint la précision la plus haute et enfin le modèle par écrêttement (winsorisation). Pour chaque modèle, j'ai calculé le coefficient de détermination et la variance résiduelle sur chacun des ensembles test et apprentissage. J'ai obtenu des résultats quasi proches pour chaque modèle.

```

--- Scénario 1 : Sans valeurs extrêmes (Méthode Z-score) ---
Lignes supprimées par Z-score : 32
R² train : 0.906, R² test : 0.906
S² train : 0.020, s² test : 0.020

--- Scénario 2 : Après écrêtage ---
R² train : 0.907, R² test : 0.905
s² train : 0.020, s² test : 0.020

--- Scénario 3 : Avec valeurs extrêmes ---
R² train : 0.906, R² test : 0.903
s² train : 0.020, RMSE test : 0.021
    
```

Dans l'optique de pousser l'analyse plus loin et mieux valider mon choix, je me suis assuré que chaque observation fasse au moins un passage dans chacun des deux ensembles test et apprentissage afin de confirmer la constance des paramètres. Pour cela, j'ai utilisé la validation croisée (K-Fold 5) en découpant l'ensemble des observations en 5 sous-ensembles et réalisant 5 itérations.

Grâce à cette méthode, j'ai choisi l'**Écrêtage** (Scénario 2) comme modèle final. Bien que le R2 soit identique au Z-score, son écart-type est presque deux fois plus faible (0,0009). Cette stabilité renforcée, couplée au fait de conserver l'intégralité des observations, en fait le modèle le plus fiable.

Toutefois dans l'analyse du scénario 3, j'ai été initialement confuse par le score de -**503,68**. J'ai compris ensuite que le R2 peut être massivement négatif hors échantillon si le modèle prédit "plus mal" que la simple moyenne à cause des **valeurs extrêmes**. Cela prouve l'instabilité totale des données brutes.


```

--- COMPARAISON FINALE PAR VALIDATION CROISÉE ---
Scénario 1 (Z-score) : Score moyen Validation Croisée (K-Fold) = 0.9061 (+/- 0.0016)
Scénario 2 (Écrêtage) : Score moyen Validation Croisée (K-Fold) = 0.9061 (+/- 0.0009)
Scénario 3 (Avec Outliers) : Score moyen Validation Croisée (K-Fold) = -503.6821 (+/- 1009.1732)
|
--- MODÈLE B (WINSORISATION) (Apprentissage) ---
n : 15991 | SR : 1495.87 | SM : 14495.13 | ST : 15991.00
R2 Train : 0.9065
    
```

5. Interprétation de la variance (ST, SM, SR)

Les calculs théoriques sur mon modèle d'apprentissage confirment la qualité de la prédiction :


- **ST = 15991.00** : Reflète la forte dispersion initiale des diamètres tumoraux entre les patients.
- **SM = 14495.13** : Environ **91%** de la variabilité est absorbée par mon modèle. C'est un résultat très satisfaisant qui prouve la pertinence des dix tests.
- **SR = 1495.87** : La part d'ombre (facteurs non mesurés, génétique) est réduite à 9%. L'erreur de prédiction ($s^2 = 0.020$) reste extrêmement faible.



6. Influence des tests médicaux (Coefficients Beta)

Grâce à la standardisation, j'ai comparé l'influence réelle de chaque test :

- **Les prédicteurs dominants** : Le test **X8** est le plus influent (coeff: ~ 0.51), suivi de **X9** (coeff: ~ 0.32). Une augmentation de ces scores corrèle fortement avec une augmentation du diamètre tumoral.
- **L'effet inverse** : Le test **X6** présente l'influence négative la plus marquée (coeff: -0.15).
- **Variables mineures** : Les tests X1 et X7 n'ont quasiment aucune influence significative sur le diagnostic.



7. Synthèse finale

Au terme de cette analyse, je conclus que la Régression Linéaire Multiple est une méthode robuste pour cette problématique, à condition d'être couplée à un nettoyage rigoureux. En privilégiant l'écrtage pour le traitement des extrêmes, j'ai optimisé la stabilité et la généralisation. La cohérence entre mes calculs théoriques (ST, SM, SR) et les graphiques de résidus valide définitivement la fiabilité de ce modèle pour la prédiction médicale.