

(Mariama, Clara, Noa : EMS-2)

## Rapport de Mission : Stratégie de Scoring pour l'Optimisation des Campagnes Épargne

### 1. Contexte et Enjeux Métier

En tant que responsables marketing opérationnel, nous faisons face à une contrainte de ressources : nos équipes commerciales ont une capacité d'appel limitée et un coût horaire élevé. Solliciter l'intégralité de la base client est non seulement inefficace financièrement, mais risque également de saturer et d'agacer nos clients.

**Notre mission :** Passer d'une logique de volume à une logique de valeur grâce à un modèle de **Régression Logistique** capable de prédire l'appétence de chaque client.

---

### 2. Méthodologie : De la Donnée Brute au Modèle Prédictif

#### A. Nettoyage et Normalisation des Données

Le succès d'un modèle dépend de la qualité de ce qu'on lui donne à "manger". Nous avons opéré un nettoyage strict :

- **Normalisation :** Harmonisation des genres et traitement des valeurs manquantes (les "unknown" sont devenus "inconnu" pour une lecture uniforme).
- **Correction Numérique :** Conversion des formats (remplacement des virgules par des points) pour permettre les calculs statistiques sur l'âge, l'IPC ou la croissance de l'emploi.
- **Traitement des Outliers :** "Clipping" de l'âge (borné entre 15 et 80 ans) pour éviter que des profils extrêmes ne faussent les tendances globales.

Nous avons aussi choisi une plage large de **15 à 80 ans** pour ne rater aucune opportunité, du premier livret jeune à l'épargne de fin de carrière. Nous avons ensuite laissé le modèle faire le tri : on remarque d'ailleurs dans nos variables que les tranches **20-40** et **40-55** sont souvent les plus réactives

#### B. Classification et Segmentation (Binning)

Pour capturer des comportements non linéaires, nous avons transformé des variables numériques en **classes sémantiques** :

- **Âge** : Segmentation par tranches de vie (20-40 ans, 40-55 ans, etc.).
- **Pression Commerciale** : Création de classes pour le nombre de contacts (1-5, 5-15, 15+).
- **Contexte Éco** : Classification de l'IPC et de la croissance de l'emploi (positif, nul, négatif) pour aider le modèle à comprendre les cycles économiques.

```
# Normalisation du genre (M devient H)
if 'genre_naissance' in df.columns:
    df['genre_naissance'] = df['genre_naissance'].replace('M', 'H')
# Normalisation des "unknown"
df = df.replace(['unknown', 'UNKNOWN'], 'inconnu')

# Nettoyage numérique (on s'assure d'avoir des points et des float pour les calculs)
cols_numeriques = [
    "age", "enfant", "duree_appel", "nb_contact", "contacts_camp_prec",
    "indic_confiance", "IPC", "croissance_emploi"]
for col in cols_numeriques:
    if col in df.columns:
        df[col] = pd.to_numeric(df[col].astype(str).str.replace(',', '.'), errors='coerce')

# Clipping de l'âge et suppression des géo vides
df['age'] = df['age'].clip(lower=15, upper=80)
df = df.dropna(subset=['geo'])

# --- 3. CLASSIFICATIONS (BINNING) ---

# Age
df["age_classe"] = pd.cut(df["age"], bins=[0, 20, 40, 55, 70, float("inf")],
                          labels=["moins_20", "20-40", "40-55", "55-70", "70+"])

# Enfants
df["enfants_classe"] = pd.cut(df["enfant"], bins=[-1, 0, 2, 5, float("inf")], labels=["0", "1-2", "3-5", "6+"])

# Durée appel
df["duree_appel_classe"] = pd.cut(df["duree_appel"], bins=[-1, 5, 30, 60, float("inf")],
                                  labels=["moins_5s", "5-30s", "30-60s", "60s+"])

# Contacts journaliers
df["contacts_jour_classe"] = pd.cut(df["nb_contact"], bins=[0, 5, 15, float("inf")],
                                    labels=["1-5", "5-15", "15+"])

# Contacts précédents
df["contacts_prec_classe"] = pd.cut(df["contacts_camp_prec"], bins=[-1, 0, 5, float("inf")],
                                    labels=["0", "1-5", "5+"])

# Croissance emploi
df["croissance_emploi_classe"] = pd.cut(df["croissance_emploi"], bins=[-10, -0.0001, 0.0001, float("inf")],
                                         labels=["negatif", "nul", "positif"])

# Indice de confiance
df["indic_confiance_classe"] = pd.cut(df["indic_confiance"], bins=[-100, -40, -30, float("inf")],
                                       labels=["inf_a_-40", "entre_-40_-30", "sup_a_-30"])

# IPC
df["IPC_classe"] = pd.cut(df["IPC"], bins=[0, 93, 94, float("inf")], labels=["90_93", "93_94", "94_plus"])
```

## C. Feature Engineering : La création de « Pépites »

J'ai voulu ajouter des données externes comme le pouvoir d'achat en fonction des communes mais, mais sans code postal précis, la jointure était risquée, on a choisi de créer de nouvelles variables

Nous avons injecté notre « expertise métier » en créant des variables croisées :

- **zero\_dette\_total** : Clients sans prêt immo, ni crédit conso, ni défaut. C'est le cœur de cible pour l'épargne.
- **potentiel\_geo\_financier** : Un score pondéré croisant le type d'emploi et la zone géographique (Urbain/Rural).
- **potentiel\_neuf** : Client jamais contacté mais dans un contexte de croissance d'emploi positive

- **client\_gold\_moment** : Identifie les clients ayant déjà souscrit par le passé et contactés lors de mois historiquement performants (Juin, Juillet, Octobre).

#### D. Éthique et Robustesse

- **Suppression des variables "Post-Appel"** : Nous avons supprimé la **durée d'appel**. Pourquoi ? Parce qu'on ne la connaît qu'une fois l'appel terminé. L'inclure aurait créé un modèle "tricheur" inutilisable en conditions réelles.
- **Filtrage des corrélations** : Nous avons identifié et supprimé les variables corrélées à plus de **0.85** pour éviter les redondances, tout en **protégeant nos variables métiers** créés à la main.

#### 1. Le Seuil de Corrélation (Nettoyage des données)

Dans le code, j'ai défini un seuil = 0.85 lors de l'analyse de la matrice de corrélation.


- **À quoi ça sert ?** Ce seuil sert à éliminer les variables "doublons". Si deux variables sont corrélées à plus de 85%, elles racontent pratiquement la même histoire (par exemple, le téléphone fixe et le téléphone portable pour un même client).
- **Pourquoi c'est important ?** Garder des variables trop similaires crée du "bruit" mathématique et peut rendre les coefficients de ta régression logistique instables ou faux.
- **Ton action spécifique** : Tu as mis en place une "liste de protection" (pepites\_a\_garder) pour t'assurer que, même si elles sont corrélées, tes variables créées à la main (comme score\_eco\_social\_1) ne soient jamais supprimées.

---

### 3. Analyse des Facteurs Clés (Le Top 15)

L'examen des coefficients nous révèle les leviers psychologiques et économiques :

- **Impact Positif** : La décroissance de l'emploi (Le modèle nous révèle un comportement d'**épargne de précaution** : plus l'environnement économique semble incertain ou se dégrade, plus nos clients ressentent le besoin de sécuriser leur avenir financier en souscrivant à nos produits d'épargne) et les périodes de mi-année (Juin/Jullet) sont des catalyseurs. Le statut "Urbain" renforce également la probabilité de souscription.
- **Impact Négatif** : Le pessimisme économique (Indice de confiance < -40) et le harcèlement téléphonique (plus de 15 contacts) sont les plus grands freins à la vente.



Nous avons aussi utilisé le paramètre `class_weight='balanced'` pour forcer le modèle à apprendre autant des souscriptions que des refus car dans la base initiale, on a plus de 70% de non-souscription qui peut causer une sorte déséquilibre sur nos test et fausser nos prédictions.

## 4.Stratégie de Ciblage

### Compromis Précision/Recall

Grâce à notre analyse du **Trade-off Precision/Recall**, nous avons ajusté le curseur pour répondre aux besoins du métier :

- **Précision (0.62)** : En fixant un seuil élevé (0.9), nous garantissons que 62% des appels passés aboutissent à une vente.
- **Recall (0.23)** : Nous acceptons de ne capter qu'une partie des ventes pour garantir que chaque appel passé soit extrêmement rentable (ROI immédiat).

### Performance du Top 30%


- **Ciblage** : En contactant seulement le **Top 30%** des clients les mieux scorés, nous captons **68,1%** des souscriptions totales.
- **Conversion** : Le taux de transformation dans ce segment atteint **22,41%**, soit plus du double du taux moyen de la base

En passant de **10% à 22,41%**, je démontre que le modèle a une **capacité de discrimination** forte. Je double l'efficacité de chaque appel passé. Pour un directeur commercial, cela signifie :

- **Moins de fatigue** pour les équipes (ils signent plus souvent).
- **Plus de rentabilité** (le coût d'acquisition d'un client est divisé par deux).
- **L'impact concret** :
  - **Côté Précision (0.62)** : Je minimise les erreurs. Quand j'appelle, j'ai raison dans 62% des cas.
  - **Côté Recall (0.23)** : J'accepte de "laisser passer" des clients qui auraient pu dire oui (ceux qui avaient un score de 0.7 ou 0.8), mais je garantis que les appels passés sont ultra-rentables.

En résumé : "J'ai utilisé deux seuils : le premier (**0.85**) pour **assainir ma base** en supprimant les variables redondantes tout en protégeant mes variables métiers. Le second (**0.9**) pour **piloter la rentabilité**, en choisissant de n'appeler que les profils ayant la plus forte probabilité de succès, ce qui garantit notre ROI immédiat."

**Pourquoi privilégier la Précision au Recall ?** Dans notre contexte de coût humain élevé, chaque appel manqué coûte cher. Nous avons choisi d'appeler "moins mais mieux" pour garantir le meilleur ROI immédiat (Retour sur Investissement immédiat) représente le gain financier direct et rapide que la banque réalise en arrêtant d'appeler des clients au hasard pour se concentrer uniquement sur les plus prometteurs.



## 5. Résultats et Recommandations Business

### Performances constatées :

- **Précision de 62 %** : Avec un seuil de 0.9, nous sommes très sélectifs. 6 appels sur 10 aboutissent à une souscription.
- **Gain de 68 %** : En ciblant uniquement le **Top 30 %** de la base, nous captions la grande majorité des ventes totales.

### Réponses aux questions stratégiques :

1. **Peut-on appeler seulement 30 % des clients ?** Oui, c'est la stratégie optimale. On réduit l'effort de 70 % tout en sauvant plus des deux tiers du business.
2. **Quels profils privilégier ?** Les cadres urbains sans dettes, contactés en période de confiance économique haute.
3. **Le modèle est-il exploitable ?** Oui. Le score peut être généré sur toute la base clients **avant** le lancement de la campagne.

