

SAE – Intégration de données dans un Data Warehouse (groupe 6)



S P O R T S O N E

I – Mis en contexte	3
II – Notre démarche	3
a) Organisation et suivi du projet	3
b) Initialisation	5
c) Démarche sur Talend (chargement des données dans l'entrepôt)	5
i) DIM_Client	5
ii) DIM_Employe.....	6
iii) DIM_Geographie	6
.....	6
iv) DIM_Produit.....	7
v) FAIT_Ventes	7
d) Démarche sur SQL et Python (création et exécution des requêtes)	8
e) Démarche sur Power BI (visualisation des données)	9
1) Stratégie client et fidélisation	
2) Performance commerciale	
3) Produit-panier	
4) Logistique-géographie	
5) Analyses avancées	
III - Conclusion et Perspectives Stratégiques	

I – Mis en contexte

SportOne est une entreprise internationale spécialisée dans la vente au détail d'articles de sport et de plein air, disposant à la fois de magasins physiques répartis dans plusieurs pays et d'une plateforme e-commerce permettant la gestion des commandes en ligne.


Face à la croissance rapide de ses ventes et à la diversification de ses canaux de distribution, SportOne génère un volume important de données provenant de sources variées : ventes en magasin, ventes en ligne, stocks, fournisseurs, clients, etc. Ces données, souvent dispersées et hétérogènes, compliquent leur exploitation et limitent la prise de décision stratégique. Cette démarche permettra de faciliter l'accès aux données pour les analyses commerciales et opérationnelles, d'améliorer leur qualité et leur cohérence, et de permettre la création de rapports et de tableaux de bord fiables pour suivre les ventes, les stocks et la performance globale de l'entreprise.

Grâce à cette intégration, SportOne disposera d'une vue consolidée et complète de ses opérations, offrant un support fiable à la prise de décision stratégique et à l'optimisation de ses performances commerciales.

II – Notre démarche

a) Organisation et suivi du projet

Pour assurer la bonne réalisation de ce projet, nous avons mis en place une organisation rigoureuse et un suivi des tâches à l'aide de l'outil **Trello**, qui nous a permis de planifier et de répartir les missions de manière efficace.



La répartition des tâches a été définie comme suit :

- **Paul** s'est chargé de **Talend Open Studio**, utilisé pour le processus ETL (Extract, Transform, Load) :
 - Extraction des données depuis les différentes sources.
 - Transformation et nettoyage des données.
 - Chargement des données dans l'entrepôt de données.
- **Abderrahman** a utilisé **Python** pour :
 - Générer les données de la dimension Time.
 - Création de la séquence de dates, création des dictionnaires de traduction et création du DataFrame.
 - Vérification de la logique des jours et exportation du fichier CSV.
- **Marzouk** a participé sur le talend, sur le Python et s'est aussi occupé de **Oracle SQL Developer** utilisé pour :
 - La création des tables de l'entrepôt de données.
 - La vérification de l'état d'alimentation des données.
 - L'exécution de requêtes SQL de validation.

- **Mariama** est le scrum master (gestion et suivi du projet, attribution des tâches et rédaction du rapport) et s'est occupée aussi du **Power BI**, utilisé pour :
 - La création des tableaux de bord.
 - La visualisation des performances de l'entreprise.
 - L'analyse interactive des données.

Cette organisation a permis de répartir clairement les responsabilités, de suivre l'avancement du projet et de garantir la qualité de l'intégration et de l'exploitation des données.

b) Initialisation



Afin de gagner du temps, un schéma en étoile a été réalisé manuellement, servant de support au travail effectué sur Talend ainsi qu'à celui réalisé sur SQL. De plus, pour une meilleure utilisation de la base de données, nous avons renommé les tables et les colonnes.

c) Démarche sur Talend (chargement des données dans l'entrepôt)

Pour la partie ETL (extract transform load), on a utilisé l'application Talend Open Studio permettant de traiter toutes les données que ce soit des txt, csv ou encore excel et de les ressortir propre dans les dimensions de notre schéma en étoile.

i) DIM_Client

Pour la dimension Client les fichiers customer.csv, le fichier MDB sur les types de client et le fichier 3.txt ont été utilisés pour avoir le nom des pays entier. Dans le tMap, on a créé une variable datepropre afin de récrire les dates sous le bon format dd/MM/yyyy car les dates avaient des problèmes de format, certaines avec des tirets ou d'autres avec des doubles slashes. Et ensuite pour avoir l'âge on l'a calculé à partir de la variable DatePropre.



The diagram illustrates a DataStage job flow for processing employee data. It starts with an 'employee' input (green icon) which feeds into 'row2 (Lookup)' (dotted line). 'row2 (Lookup)' feeds into 'tMap_1' (blue icon). 'tMap_1' also receives input from 'organization' (green icon) via 'row1 (Main)' (solid line). 'tMap_1' outputs to 'tFileOutputDelimited_1' (green icon) via 'row3 (Main)' (solid line). Additionally, 'tMap_1' feeds into 'org_level' (green icon) via 'org_levelpropere (Lookup)' (dotted line). 'org_level' feeds into 'tMap_2' (blue icon) via 'row3 (Main)' (solid line).



iii) DIM_Geographie

The screenshot displays the Microsoft Access database interface. The left pane shows the 'tblEmp' table structure, which includes fields: emp_id (Number), emp_firstname (Text), emp_lastname (Text), emp_salary (Number), emp_hiredate (Date/Time), emp_job (Text), emp_dept (Text), emp_mgr (Text), emp_comm (Text), emp_email (Text), emp_phone (Text), emp_fax (Text), emp_address (Text), emp_city (Text), emp_state (Text), emp_zip (Text), emp_country (Text), emp_email2 (Text), emp_email3 (Text), emp_email4 (Text), emp_email5 (Text), emp_email6 (Text), emp_email7 (Text), emp_email8 (Text), emp_email9 (Text), emp_email10 (Text), emp_email11 (Text), emp_email12 (Text), emp_email13 (Text), emp_email14 (Text), emp_email15 (Text), emp_email16 (Text), emp_email17 (Text), emp_email18 (Text), emp_email19 (Text), emp_email20 (Text), emp_email21 (Text), emp_email22 (Text), emp_email23 (Text), emp_email24 (Text), emp_email25 (Text), emp_email26 (Text), emp_email27 (Text), emp_email28 (Text), emp_email29 (Text), emp_email30 (Text), emp_email31 (Text), emp_email32 (Text), emp_email33 (Text), emp_email34 (Text), emp_email35 (Text), emp_email36 (Text), emp_email37 (Text), emp_email38 (Text), emp_email39 (Text), emp_email40 (Text), emp_email41 (Text), emp_email42 (Text), emp_email43 (Text), emp_email44 (Text), emp_email45 (Text), emp_email46 (Text), emp_email47 (Text), emp_email48 (Text), emp_email49 (Text), emp_email50 (Text), emp_email51 (Text), emp_email52 (Text), emp_email53 (Text), emp_email54 (Text), emp_email55 (Text), emp_email56 (Text), emp_email57 (Text), emp_email58 (Text), emp_email59 (Text), emp_email60 (Text), emp_email61 (Text), emp_email62 (Text), emp_email63 (Text), emp_email64 (Text), emp_email65 (Text), emp_email66 (Text), emp_email67 (Text), emp_email68 (Text), emp_email69 (Text), emp_email70 (Text), emp_email71 (Text), emp_email72 (Text), emp_email73 (Text), emp_email74 (Text), emp_email75 (Text), emp_email76 (Text), emp_email77 (Text), emp_email78 (Text), emp_email79 (Text), emp_email80 (Text), emp_email81 (Text), emp_email82 (Text), emp_email83 (Text), emp_email84 (Text), emp_email85 (Text), emp_email86 (Text), emp_email87 (Text), emp_email88 (Text), emp_email89 (Text), emp_email90 (Text), emp_email91 (Text), emp_email92 (Text), emp_email93 (Text), emp_email94 (Text), emp_email95 (Text), emp_email96 (Text), emp_email97 (Text), emp_email98 (Text), emp_email99 (Text), emp_email100 (Text).

The right pane shows the 'tblEmp' table data, which includes fields: emp_id, emp_firstname, emp_lastname, emp_salary, emp_hiredate, emp_job, emp_dept, emp_mgr, emp_comm, emp_email, emp_phone, emp_fax, emp_address, emp_city, emp_state, emp_zip, emp_country, emp_email2, emp_email3, emp_email4, emp_email5, emp_email6, emp_email7, emp_email8, emp_email9, emp_email10, emp_email11, emp_email12, emp_email13, emp_email14, emp_email15, emp_email16, emp_email17, emp_email18, emp_email19, emp_email20, emp_email21, emp_email22, emp_email23, emp_email24, emp_email25, emp_email26, emp_email27, emp_email28, emp_email29, emp_email30, emp_email31, emp_email32, emp_email33, emp_email34, emp_email35, emp_email36, emp_email37, emp_email38, emp_email39, emp_email40, emp_email41, emp_email42, emp_email43, emp_email44, emp_email45, emp_email46, emp_email47, emp_email48, emp_email49, emp_email50, emp_email51, emp_email52, emp_email53, emp_email54, emp_email55, emp_email56, emp_email57, emp_email58, emp_email59, emp_email60, emp_email61, emp_email62, emp_email63, emp_email64, emp_email65, emp_email66, emp_email67, emp_email68, emp_email69, emp_email70, emp_email71, emp_email72, emp_email73, emp_email74, emp_email75, emp_email76, emp_email77, emp_email78, emp_email79, emp_email80, emp_email81, emp_email82, emp_email83, emp_email84, emp_email85, emp_email86, emp_email87, emp_email88, emp_email89, emp_email90, emp_email91, emp_email92, emp_email93, emp_email94, emp_email95, emp_email96, emp_email97, emp_email98, emp_email99, emp_email100.



iv) DIM_Produit

Pour la dimension Produit, on a utilisé les fichiers product_list.csv ainsi que supplier.csv. Afin de récupérer les lignes, catégories et groupe de chacun des produits, le fichier product_list a été mis quatre fois en entrée du tMap. Cela a été plutôt compliqué car les référence ID était écrit au format 1,01E+11 alors les ID étaient écrits en entier.



v) FAIT_Ventes

Pour la table des faits, les fichiers orders.csv order_item.csv ainsi que customer.csv ont été utilisé afin de récupérer l'ID de l'adresse. Pour les orders, les dates étaient également erronées, je les ai remis au propre comme dans la dimension Client.



vi) Démarche sur SQL et Python (création et exécution des requêtes)

Pour répondre aux besoins d'analyse et de reporting, nous avons écarté le modèle relationnel classique au profit d'une modélisation dimensionnelle en Schéma en Étoile. Nous avons structuré la base autour d'une table centrale de faits (FAIT) contenant les métriques quantitatives (Prix, Quantité), entourée de tables de dimensions (DIM_CLIENT, DIM_TEMPS, DIM_GEOGRAPHIE, etc.).

Stratégie de Chargement

En amont de cette étape, le traitement ETL réalisé sous Talend nous a fourni des fichiers CSV propres et structurés. Le défi technique ne résidait donc pas dans la qualité de la donnée, mais dans la stratégie d'alimentation de la base Oracle à partir de ces fichiers plats.

Plutôt que d'utiliser des outils d'importation graphiques souvent lents ou limités pour les gros volumes, nous avons développé une sorte de moulinette d'intégration en Python.

Formatage Technique

Bien que les données issues de Talend soient propres, elles n'étaient pas directement compréhensibles par Oracle sous forme de requêtes SQL. Nous avons codé des scripts Python pour lire les CSV et générer les ordres **INSERT INTO**. Ce script assurait ainsi la conformité syntaxique stricte exigée par Oracle.

Gestion de la Volumétrie et Segmentation

Face à la volumétrie importante de certaines tables générées par Talend, la création d'un fichier SQL unique posait problème (timeouts). Nous avons donc décidé d'ajouter au script Python une fonctionnalité qui permettrait de segmenter automatiquement la sortie. Au lieu d'un bloc monolithique, le programme découpait les instructions en plusieurs fichiers plus légers (**ex: 10 fichiers pour la table de FAITS**), facilitant leur digestion par le serveur de base de données.

Orchestration et Automatisation

Cette segmentation créait un risque opérationnel : devoir exécuter manuellement une douzaine de scripts à la suite est fastidieux. On a donc ainsi décidé d'ajouter une brique d'automatisation au script Python. En plus de générer les segments de données, il produit désormais un script maître d'orchestration (**LANCER_TOUT.sql**).

Analyse Critique et Perspectives d'Optimisation

Si la stratégie de génération de scripts SQL a permis de contourner efficacement les restrictions de l'environnement universitaire pour mener le projet à terme, une analyse rétrospective en souligne les limites. Notre solution reposait en effet sur une automatisation "**basée sur fichiers**", qui imposait une étape intermédiaire de matérialisation des données sur le disque (**artefacts.sql**) avant leur exécution par l'utilisateur. Cette approche en deux temps, bien que robuste et portable, induisait une redondance de stockage et une latence d'entrées/sorties qui auraient pu être évitées par une méthode d'injection directe ("In-

Memory"), connectant le script Python directement à la base de données sans transition par le disque.

On aurait eu alors un gain de performance énorme et le script Python aurait pu attraper une erreur sur une ligne précise, la logger dans un éventuelle fichier "**rejets**", et continuer l'insertion des autres lignes sans planter.

IV) Démarche sur Power BI (visualisation des données)

Pour bien entamer le travail sur la visualisation, un premier travail a été fait sur Power Query ; la création des colonnes :

- **Segmentation** qui s'est basée sur la colonne type_client afin de mieux les classer et de les hiérarchiser
- **Classe d'âge** qui s'est basée sur la colonne âge permettant de les classer pour ainsi faciliter l'analyse
- **Durée de livraison** qui a été calculée par la soustraction entre la date de commande et la date de livraison

Dans le but de mieux organiser et structurer l'analyse cinq pages ont été utilisées et chaque page traite un thème bien défini : **stratégie client et fidélisation**, **performance commerciale**, **produit-panier**, **logistique-géographie**, **analyses avancées**.

1. Stratégie client et fidélisation

Ce tableau de bord met en évidence une base de **89,75 K clients**, suffisante pour réaliser des analyses pertinentes et orienter les décisions stratégiques. La répartition par genre montre une **légère majorité d'hommes (55,21 %) contre 44,79 % de femmes**, ce qui indique une clientèle **presque équilibrée**. Cette proximité entre les deux genres suggère que l'offre de l'entreprise s'adresse à un public large et mixte, et qu'il est pertinent de conserver une stratégie marketing inclusive plutôt que fortement genrée.


La segmentation par âge révèle que la clientèle est majoritairement **adulte**, avec une concentration importante entre **36 et 60 ans**, ces deux classes regroupant à elles seules plus de **41 000 clients**. Ce constat suggère un pouvoir d'achat plus élevé et une fidélité plus forte, ce qui en fait des segments prioritaires pour les actions de fidélisation. À l'inverse, les **moins de 25 ans**, moins représentés, constituent un levier de croissance potentiel à travers des offres adaptées et une communication plus digitale.

L'analyse géographique montre que les clients sont principalement situés en **Europe et en Amérique du Nord**, confirmant l'importance stratégique de ces marchés dans le chiffre d'affaires de l'entreprise. Ces zones doivent être consolidées, tandis que les régions moins représentées peuvent faire l'objet de stratégies de développement ciblées.

L'étude du **chiffre d'affaires moyen par âge et par catégorie de produit** met en évidence que certaines catégories, notamment **Outdoors et Sports**, génèrent des montants moyens plus élevés chez les clients adultes, en particulier entre **36 et 60 ans**. Cette information est

directement actionnable, car elle permet d'orienter la mise en avant des produits, la politique de prix et les offres personnalisées vers les segments les plus rentables.

Enfin, l'analyse des types de clients montre que les **clients Gold et les membres actifs** génèrent le plus grand volume de commandes, avec un écart significatif par rapport aux clients occasionnels. Ces résultats soulignent l'importance de renforcer les programmes de fidélité afin de conserver ces clients à forte valeur et d'inciter les clients occasionnels à augmenter leur fréquence d'achat.



2. Performance commerciale

Ce tableau de bord met en évidence une **performance commerciale globale de 59,26 M€ de chiffre d'affaires**, ce qui permet d'évaluer l'efficacité des ventes et la contribution des ressources humaines à la création de valeur. Ce niveau de chiffre d'affaires constitue un indicateur clé pour mesurer la rentabilité globale et comparer les performances entre pays, produits et types d'employés.


L'analyse de la **corrélation entre le chiffre d'affaires et la masse salariale par pays** montre que l'Europe génère le chiffre d'affaires le plus élevé (au-delà de **40 M€**) pour un niveau de salaires important, traduisant une forte activité commerciale mais aussi des coûts élevés. À l'inverse, des zones comme l'Amérique du Nord ou l'Australie/Pacifique présentent des masses salariales comparables mais un chiffre d'affaires nettement plus faible, ce qui peut indiquer un potentiel d'optimisation de la productivité ou une nécessité d'adapter la stratégie commerciale locale.

L'évolution annuelle du chiffre d'affaires révèle une **croissance irrégulière mais globalement positive entre 2017 et 2021**, avec des pics dépassant **1,5 M€** sur certaines périodes. La baisse observée en fin de période peut s'expliquer par un effet conjoncturel ou une donnée partielle sur l'année 2022. Cette analyse temporelle permet à l'entreprise d'identifier les cycles d'activité, les périodes de forte demande et d'anticiper les fluctuations futures.

L'analyse du **chiffre d'affaires généré par type d'employés** met en évidence que les canaux **Internet/Catalog Sales (17,23 M€)** et les **Sales Rep I (15,77 M€)** sont les plus performants. À l'inverse, les **trainees et employés temporaires** génèrent un chiffre d'affaires très limité (moins de **0,5 M€**), ce qui souligne l'importance des profils expérimentés dans la performance commerciale. Ces résultats peuvent orienter les décisions de recrutement, de formation et d'allocation des ressources.

Enfin, l'analyse de la **moyenne du taux de remise par catégorie de produit** montre que certaines catégories, comme **Team Sports (1,10 %)** et **Swim Sports (0,64 %)**, bénéficient de remises plus élevées, ce qui peut traduire une stratégie de stimulation de la demande ou une pression concurrentielle plus forte. À l'inverse, les catégories avec des remises très faibles, comme **Indoor Sports ou les produits non catégorisés**, suggèrent une meilleure marge ou une demande plus stable. Cette information permet d'ajuster la politique promotionnelle afin de maximiser à la fois les volumes de ventes et la rentabilité.

Dans l'ensemble, ce tableau de bord permet de croiser **performance commerciale et performance RH**, en identifiant les zones géographiques, les profils d'employés et les catégories de produits les plus rentables. Il constitue ainsi un outil d'aide à la décision pour optimiser les coûts, améliorer la productivité et renforcer la stratégie commerciale de l'entreprise.



3. Produit-panier


Ce tableau de bord met en évidence une activité commerciale très soutenue avec un total de **416,99 K commandes**, ce qui traduit un volume de ventes élevé et une forte interaction entre les clients et les produits. Cet indicateur est essentiel pour évaluer la performance globale des ventes et analyser le comportement d'achat des clients.

L'analyse du nombre de commandes par catégorie de produit montre que les catégories **Clothes (79 K commandes)**, **Assorted Sports (60 K)** et **Shoes (59 K)** sont les plus demandées. Ces catégories constituent le socle du volume de ventes de l'entreprise et doivent être sécurisées en termes de stock et de disponibilité. À l'inverse, des catégories comme **Indoor Sports (7 K)** ou **Racket Sports (14 K)** génèrent moins de commandes, ce qui peut indiquer une demande plus faible ou un positionnement plus niche.

L'étude du chiffre d'affaires par segment de clients révèle que les **Gold Active Members** sont les plus rentables avec **13,8 M€ de chiffre d'affaires**, suivis des **Gold Standard Members (9,9 M€)** et des **Active Members (9,7 M€)**. À l'opposé, les segments **occasionnels et autres** génèrent un chiffre d'affaires plus faible, inférieur à **6 M€**. Ces résultats confirment que la fidélité client joue un rôle clé dans la création de valeur et justifient le renforcement des programmes de fidélisation.

L'analyse des influenceurs clés montre que le **pays** est un facteur déterminant du volume de commandes par client. Les clients situés au **Canada** présentent la moyenne de commandes la plus élevée, suivis de l'Italie et de l'Australie. Ce constat permet à l'entreprise d'identifier les marchés où les clients sont les plus engagés et d'y concentrer les actions commerciales et promotionnelles. De plus, certaines catégories comme **Golf** apparaissent comme des leviers spécifiques influençant positivement le nombre de commandes.

Dans l'ensemble, ce tableau de bord permet de mieux comprendre la composition du panier client et les leviers qui influencent le comportement d'achat. Il fournit des informations directement actionnables pour optimiser la gestion des stocks, cibler les segments les plus rentables et adapter la stratégie commerciale selon les pays et les catégories de produits, contribuant ainsi à une amélioration durable de la performance globale.




4. Logistique-géographie

L'analyse de ce tableau de bord révèle une entreprise **SportOne** solidement implantée à l'international, avec un chiffre d'affaires total de **59,26 millions d'euros** sur la période 2017-2022. La performance commerciale est largement portée par le marché européen, l'Allemagne s'imposant comme le premier contributeur financier devant les États-Unis et l'Espagne, ce qui est corroboré par la forte densité de magasins visibles sur la cartographie en Europe.

Sur le plan logistique, l'entreprise affiche une grande efficacité avec des délais de livraison moyens extrêmement courts, oscillant entre **0,89 jour** (Canada) et **1,51 jour** (Danemark), témoignant d'une chaîne d'approvisionnement réactive et bien structurée. Toutefois, cette domination commerciale s'accompagne d'une stratégie promotionnelle agressive, puisque le taux de remise maximal atteint **60 %** dans les pays générant le plus de revenus, comme la France ou l'Allemagne, ce qui pourrait peser sur les marges nettes.

Enfin, la répartition géographique montre des opportunités de croissance majeures en Asie, en Afrique et en Amérique du Sud, zones où la présence de magasins reste encore marginale malgré le statut d'entreprise internationale de SportOne.




5. Analyses avancées

Cette page d'analyses avancées démontre la capacité de **SportOne** à transformer ses données brutes en leviers stratégiques grâce à l'utilisation d'outils d'intelligence décisionnelle. L'étude de l'**évolution du nombre de clients** révèle une forte volatilité, avec des pics historiques dépassant les **11 000 clients** début 2017, suivis de cycles de fluctuation marqués par une chute atypique à **0,9K** début 2022, ce qui justifie une [alerte sur la rétention client](#).

Pour comprendre la structure de ces revenus, l'**arbre de décomposition** met en lumière que sur un chiffre d'affaires total de **59,26 millions d'euros**, l'Allemagne est le moteur principal avec **14,08 millions**, où le segment des **chaussures (Shoes)** se distingue comme une catégorie clé, particulièrement auprès des membres "**Gold Active**".

Parallèlement, le graphique de **corrélation entre le prix unitaire et les quantités** confirme une forte élasticité de la demande : le gros des volumes se concentre sur des produits à bas prix (moins de 100€), tandis que les articles premium à plus de 400€ restent des marchés de niche. Enfin, l'intégration d'un modèle de **prévision (forecasting)** sur le chiffre d'affaires projette une tendance globalement stable pour les deux années à venir (2023-2024), bien que l'élargissement de l'intervalle de confiance (zone grisée) suggère [une incertitude accrue qui nécessite une surveillance rigoureuse des conditions de marché pour sécuriser la croissance future](#).



III -Conclusion et Perspectives Stratégiques

La réalisation de cet entrepôt de données pour **SportOne** a permis de transformer un ensemble de fichiers disparates (MDB, CSV, Excel) en un outil de pilotage robuste. Le processus **ETL via Talend** a été crucial pour résoudre les problèmes d'incohérences et de données éparpillées, notamment pour les informations sur les employés et le catalogue produit. L'architecture en étoile ainsi mise en place offre aujourd'hui une vision transverse de la performance, permettant de croiser les dimensions temporelles, géographiques et produits pour expliquer les variations du chiffre d'affaires, qui s'élève à plus de **59 millions d'euros** sur la période traitée.

L'analyse approfondie des tableaux de bord révèle que si **SportOne** bénéficie d'une logistique performante et d'une assise solide en Europe, elle fait face à des défis majeurs en matière de fidélisation, comme l'indique la volatilité du nombre de clients. L'utilisation de **l'intelligence artificielle de Power BI** pour la détection d'anomalies et le forecasting montre une stagnation prévisionnelle des ventes, ce qui suggère que l'entreprise doit désormais pivoter. Il est recommandé de réduire la dépendance aux remises agressives (atteignant 60%) et de se concentrer sur le développement des segments à haute valeur ajoutée, tels que les membres **"Gold Active"** dans la catégorie **"Shoes"**, identifiés comme les plus rentables via l'arbre de décomposition.

En conclusion, ce projet démontre que la qualité de l'intégration des données est le socle indispensable à toute analyse prédictive. Pour la suite, l'entreprise pourrait intégrer des données externes, comme les tendances météo ou les réseaux sociaux, afin d'affiner encore davantage ses prévisions de ventes et d'optimiser ses stocks de produits de plein air en temps réel.

CARNOVALI Paul
DIOUF Mariama
SABI Marzouk
JENFI Abderrahman



BUT SD2 EMS 25-26